

# Cours: Théorie des langages & Compilation

## Chapitre 2: Les grammaires

Réalisé par:

Dr. Sakka Rouis Taoufik

1

### Ch2: Les grammaires

#### I. Grammaire

##### Définition

Une grammaire est un moyen permettant de décrire la construction des mots d'un langage.

La définition d'une grammaire permet de:

- Raisonner sur le langage
- Construire des algorithmes efficaces pour le traitement des langages
- Faciliter l'apprentissage des langages.

2

## Ch2: Les grammaires

### I. Grammaire

#### Exemple introductif

Pour analyser une classe de phrases simples en français, on peut supposer qu'une phrase est construite de la manière suivante :

- PHRASE → ARTICLE SUJET VERBE ARTICLE COMPLEMENT
- ARTICLE → "un" ou "le "
- SUJET → "garçon" ou "fille"
- VERBE → "voit" ou "mange" ou "porte "
- COMPLEMENT → ARTICLE NOM ADJECTIF
- NOM → "livre" ou "plat" ou "wagon"
- ADJECTIF → "bleu" ou "rouge" ou "vert "

En faisant des substitutions (on remplace les parties gauches par les parties droites) on arrive à générer les deux phrases suivantes.

Le garçon voit un livre rouge

Une fille mange le plat vert

3

## Ch2: Les grammaires

### I. Grammaire

#### Définition Formelle

Une grammaire est définie par un quadruplet  $\langle T, N, S, R \rangle$

- $T$  est un ensemble fini de symboles dits terminaux, on l'appelle également **vocabulaire terminal** ;
- $N$  est un ensemble fini (disjoint de  $T$ ) de symboles dits **non-terminaux** ou encore **concepts** ;
- $S$  **un** **non-terminal** particulier appelé **axiome** (point de départ de la dérivation) ;
- $R$  est un ensemble de règles de productions de la forme  $g \rightarrow d$  tel que  $g \in (T \cup N)^+$  et  $d \in (T \cup N)^*$ .  
La notation  $g \rightarrow d$  est appelée une dérivation (ou production) et signifie que  $g$  peut être remplacé par  $d$ .

4

## Ch2: Les grammaires

### I. Grammaire

#### Conventions:

Les lettres majuscules sont utilisées pour les non-terminaux  
 Les lettres minuscules sont utilisées pour représenter les terminaux.  
 Les règles de la forme " $\epsilon \rightarrow \dots$  **sont interdites**."

Soit une suite de dérivations :  $w_1 \rightarrow w_2 \rightarrow w_3 \rightarrow \dots \rightarrow w_n$   
 alors on écrira :  $w_1 \rightarrow^* w_n$ .  
 On dit alors qu'il y a une chaîne de dérivation qui mène de  $w_1$  vers  $w_n$ .

#### Exemple 1:

Soit la grammaire  $G = \langle \{a\}, \{S\}, S, \{S \rightarrow aS \mid \epsilon\} \rangle$ .

→ On peut construire la chaîne de dérivation suivante :

$S \rightarrow aS \rightarrow aaS \rightarrow aaaS \dots$

5

## Ch2: Les grammaires

### I. Grammaire

#### Exemple 2:

Pour l'exemple des phrases en français, on peut définir la grammaire suivante:

$G = \langle T, N, S, R \rangle$  Avec

$T = \{\text{garçon, fille, voit, mange, porte, un, le, livre, plat, wagon, bleu, rouge, vert}\}$

$N = \{\text{PHRASE, ARTICLE, SUJET, VERBE, COMPLEMENT, NOM, ADJECTIF}\}$

$S = \text{PHRASE}$

$R = \{$   
      $\text{PHRASE} \rightarrow \text{ARTICLE SUJET VERBE ARTICLE COMPLEMENT}$   
      $\text{SUJET} \rightarrow \text{"garçon" ou "fille"}$   
      $\text{VERBE} \rightarrow \text{"voit" ou "mange" ou "porte"}$   
      $\text{COMPLEMENT} \rightarrow \text{ARTICLE NOM ADJECTIF}$   
      $\text{ARTICLE} \rightarrow \text{"un" ou "le"}$   
      $\text{NOM} \rightarrow \text{"livre" ou "plat" ou "wagon"}$   
      $\text{ADJECTIF} \rightarrow \text{"bleu" ou "rouge" ou "vert" } \}$

6

## Ch2: Les grammaires

## I. Grammaire

**Définition :** Soit une grammaire  $G = \langle T, N, S, R \rangle$ .

On dit que le mot  $\omega \in T^*$  est dérivé (ou généré) à partir de la grammaire  $G$  s'il existe une chaîne de dérivation qui mène de l'axiome vers  $\omega$ . ( $S \xrightarrow{*} \omega$ )

Le langage de tous les mots générés par la grammaire  $G$  est noté  $L(G)$ .

**Notez Bien:** une expression, dérivée à partir de l'axiome, n'est considérée appartenant à  $L(G)$  que si elle ne comporte **aucun non-terminal**.

**Exemple 3 :**

Soit la grammaire  $G = \langle \{a, b\}, \{S, T\}, S, \{S \rightarrow aS \mid aT, T \rightarrow bT \mid b\} \rangle$ .

→  $G$  génère le mot  $abb$  parce que  $S \rightarrow aT \rightarrow abT \rightarrow abb$

→  $G$  génère le mot  $aab$  parce que  $S \rightarrow aS \rightarrow aaT \rightarrow aab$ .

→ On peut conclure que le langage généré par cette grammaire est:

$$L(G) = \{\omega \in \{a, b\}^* \mid \omega = a^m b^n, m > 0, n > 0\}.$$

7

## Ch2: Les grammaires

## II. Arbre syntaxique d'une Grammaire

**Définition :** Étant donnée une grammaire  $G = \langle T, N, S, R \rangle$ ,

**Les arbres de syntaxe de  $G$**  sont des arbres où les noeuds internes sont étiquetés par des symboles de  $N$ , et les feuilles étiquetés par des symboles de  $T$ , tels que, si le noeud  $p$  apparaît dans l'arbre et si la règle  $p \rightarrow a_1 \dots a_n$  ( $a_i$  terminal ou non terminal) est utilisée dans la dérivation, alors le noeud  $p$  possède  $n$  fils correspondant aux symboles  $a_i$ .

Si l'arbre syntaxique a comme racine  $S$ , alors il est dit arbre de dérivation du mot  $\omega$ , avec  $\omega$  est le mot obtenu en prenant les feuilles de l'arbre dans le sens : gauche vers droite et niveau bas vers niveau haut.


**Exemple 4 :** Soit la grammaire

$$G = \langle \{a, b\}, \{S, T\}, S, \{S \rightarrow aS \mid aT, T \rightarrow bT \mid b\} \rangle$$

$G$  génère le mot  $aab$

Selon la chaîne de dérivation  $S \rightarrow aS \rightarrow aaT \rightarrow aab$ .

Ce qui donne donc l'arbre syntaxique suivant :



8

## Ch2: Les grammaires

### III. Classification de Chomsky

La classification de Chomsky est un moyen permettant de maîtriser la complexité des langages ainsi que celle des grammaires qui les génèrent. En effet, certains langages sont plutôt simples et peuvent être décrits par des grammaires facilement compréhensibles (comme l'exemple précédent).

→ Il existe des langages d'une telle complexité que les grammaires qui les génèrent sont trop difficiles à appréhender (par exemple,  $\{a^n \mid n \text{ est premier}\}$ ).

→ Il faut savoir que plus une grammaire est complexe à définir, plus les algorithmes qui la manipulent (si jamais ils existent) sont difficiles à apprendre et à mettre en œuvre.

→ On arrive alors à une conclusion bien simple et pleine de bon sens : "utiliser des algorithmes simples pour des langages simples générés par des grammaires simples et réserver les algorithmes difficiles aux langages et grammaires complexes".

9

## Ch2: Les grammaires

### III. Classification de Chomsky

Une question clé apparaît alors : comment mesurer la complexité d'une grammaire ou d'un langage ?

On peut écarter la cardinalité d'un langage puisqu'elle ne permet pas de distinguer langage simple d'un langage complexe.

Noam Chomsky a eu le génie de remarquer que la complexité d'une grammaire (et celle du langage aussi) dépend de la forme des règles de production de celle-ci.

Chomsky a ainsi proposé **quatre classes** (hiérarchiques) de grammaires (et de langages) de sorte qu'une grammaire de type  $i$  génère un langage de type  $j$  tel que  $j \geq i$ .

10

## Ch2: Les grammaires

## III. Classification de Chomsky

## ❖ Grammaire de Type 3 (Régulière / Linéaire):

## ➤ (régulière à droite):

Toutes les règles de production sont de la forme  $A \rightarrow \omega B$  ou  $A \rightarrow \omega$   
où

$$A \in N$$

$$\omega \in T^* \quad (\text{Rappelant que } \varepsilon \in T^*)$$

$$B \in N \quad (\text{attention } B \in N \text{ et pas } B \in N^*)$$

## ➤ (régulière à gauche):

Toutes les règles de production sont de la forme  $A \rightarrow B\omega$  ou  $A \rightarrow \omega$   
où

$$A \in N$$

$$\omega \in T^* \quad (\text{Rappelant que } \varepsilon \in T^*)$$

$$B \in N \quad (\text{attention } B \in N \text{ et pas } B \in N^*)$$

11

## Ch2: Les grammaires

## III. Classification de Chomsky

## ❖ Grammaire de Type 3 (Régulière / Linéaire):

**Remarque 1:** Dans les deux sous types, pour chaque règle de production, on a un seul symbole non terminal.

**Remarque 2:** Si  $\varepsilon \in L(G)$  alors  $S \rightarrow \varepsilon$  fait partie des règles de production

## ➤ Exemple

$$\begin{cases} S \rightarrow aS|T|abU|cc \\ T \rightarrow cT|\varepsilon \\ U \rightarrow abS \end{cases}$$

12

## Ch2: Les grammaires

## III. Classification de Chomsky

❖ **Grammaire de Type 2 (hors-contexte):**

➤ **Toutes** les règles de production sont de la forme  $g \rightarrow d$

où

$$\begin{aligned} g &\in N \\ d &\in (T \cup N)^* \end{aligned}$$

**Remarque :** Pour chaque règle de production, la **partie gauche** est composée d'un seul symbole non terminal.

➤ **Exemple**

$$S \rightarrow aBa \mid \epsilon$$

$$B \rightarrow bB \mid b$$

13

## Ch2: Les grammaires

## III. Classification de Chomsky

❖ **Grammaire de Type 1 (contextuelle):**

➤ **Toutes** les règles de production sont de la forme  $g \rightarrow d$

tel que

$$\begin{aligned} g &\in (T \cup N)^+ \\ d &\in (T \cup N)^* \\ |g| &\leq |d| \end{aligned}$$

De plus, si  $\epsilon$  apparaît à droite alors la partie gauche doit seulement contenir  $S$  (l'axiome).

➤ **Exemple**

$$S \rightarrow bBC \mid a$$

$$B \rightarrow aC \mid aBa \mid S$$

$$aC \rightarrow aS$$

14

## Ch2: Les grammaires

## III. Classification de Chomsky

❖ **Grammaire de Type 0 (aucune restriction):**

➤ **Toutes** les règles de production sont de la forme  $g \rightarrow d$

$$g \in (T \cup N)^+$$

$$d \in (T \cup N)^*$$

➤ **Exemple**

$$S \rightarrow bBC \mid \varepsilon$$

$$B \rightarrow aCa \mid aBa \mid S$$

$$aC \rightarrow a$$

**Remarque :** De classe 0 si il existe une règle tq la partie gauche est supérieure à celle de la partie droite ( $aC \rightarrow a$  dans l'exemple ci-dessus)

15

## Ch2: Les grammaires

## III. Classification de Chomsky

➤ **Propriété 1:**

Les grammaires de type 0 englobent les grammaires de type 1 qui englobent les grammaires de type 2 qui englobent les grammaires de type 3.

Les grammaires hors contexte (Type 2) (et donc aussi les grammaires régulières) jouent un rôle particulièrement important en informatique car la plupart des analyseurs syntaxiques performants ont été développés pour cette catégorie de grammaires.

16



## Ch2: Les grammaires

## IV. Exercices d'application

**Exercice 1:**

Classifier les grammaires suivantes selon la hiérarchie de Chomsky.  
Justifier brièvement votre réponse.

- |   |   |
|---|---|
| <p><b>A)</b> <math>S \rightarrow aA</math><br/> <math>A \rightarrow aS \mid aB</math><br/> <math>B \rightarrow bC</math><br/> <math>C \rightarrow bD</math><br/> <math>D \rightarrow b \mid bB</math></p> | <p><b>C)</b> <math>S \rightarrow bXZ \mid aB</math><br/> <math>B \rightarrow XY \mid S</math><br/> <math>aZ \rightarrow aS</math><br/> <math>bZ \rightarrow aB</math><br/> <math>X \rightarrow a \mid \varepsilon</math><br/> <math>Y \rightarrow aa \mid aB</math></p> |
| <p><b>B)</b> <math>S \rightarrow aS \mid aAbb</math><br/> <math>A \rightarrow \varepsilon \mid aAbb</math></p>  | <p><b>D)</b> <math>S \rightarrow \varepsilon</math></p>   |

17

## Ch2: Les grammaires

## IV. Exercices d'application

**Exercice 2:**

Soit  $G$  la grammaire formelle suivante:

$S \rightarrow ABC$   
 $A \rightarrow a$   
 $aB \rightarrow b$   
 $C \rightarrow c$

Quel est le langage généré par la grammaire  $G$  tout en précisant son type?

18

## Ch2: Les grammaires

## IV. Exercices d'application

**Exercice 3:**

Trouver une grammaire à contexte libre G pour le langage L suivant:

$$L = \{ a^{2i+1} c^j b^{2i+1} \mid i \geq 0 \text{ et } 0 \leq j \leq 1 \}$$

**Exercice 4:**

Trouver une grammaire à contexte libre G pour le langage L suivant:

$$L = \{ \omega \omega^T \mid \omega \in \{a, b\}^*, \omega^T \text{ est le miroir de } \omega \}$$

**Exercice 5:**

a) Trouver une grammaire formelle G1 pour le langage

$$L1 = \{ a^i b^j a^i \mid i, j \geq 1 \}$$

b) Démontrer ensuite que  $L(G1) = L1$  en précisant le type de G1.

19

## Ch2: Les grammaires

## IV. Exercices d'application

**Exercice 6:**

Soit le mot  $x = ((acbc)^R.baca)^R$  ( $\alpha^R$  désigne le reflet miroir de  $\alpha$ )

- 1) Donner la chaîne de caractères à laquelle x est égal.
- 2) Quelle est la valeur de  $|x|$ ,  $|x|_a$ ,  $|x|_b$  et  $|x|_c$  ?
- 3) Donner un préfixe propre de x contenant au moins deux lettres 'c'.
- 4) Donner un suffixe propre de x contenant une seule lettre 'a'.

**Exercice 7 :** Soit la grammaire  $G = (\{a, b, c\}, \{S, A\}, S, P)$  ;

où P contient les règles suivantes :  $S \rightarrow aS \mid bA$  ;  $A \rightarrow cA \mid \varepsilon$

- a) Déterminer si les mots  $w1 = abac$ ,  $w2 = aabccc$ ,  $w3 = cabbac$  et  $w4 = ab$  sont générés par G.
- b) Trouver le langage généré par G ( qu'on note  $L(G)$  ).

20

**Ch2: Les grammaires****IV. Exercices d'application****Exercice 8:**

Pour chacun des langages suivants, donner des exemples de mots contenus dans chacun des langages, et des grammaires qui engendrent chacun des langages ( $L_i$ ) avec  $i=1,\dots,5$  :

- 1)  $L_1 = \{ w \in \{a, b, c\}^* / w \text{ commence par la lettre 'a'} \}$  ;
- 2)  $L_2 = \{ w \in \{a, b, c\}^* / w \text{ se termine par la lettre 'a'} \}$  ;
- 3)  $L_3 = \{ w \in \{a, b, c\}^* / w \text{ contient au moins une occurrence de la lettre 'a'} \}$  ;
- 4)  $L_4 = \{ w \in \{a, b, c\}^* / w \text{ contient au moins deux occurrences la lettre 'a'} \}$  ;
- 5)  $L_5 = \{ w \in \{a, b, c\}^* / w \text{ contient au moins deux occurrences consécutives de la lettre 'a'} \}$ .